

■ Language Detector

Guida alla Configurazione e all'Esecuzione

Istruzioni passo-passo per installare, configurare
ed eseguire il progetto da zero

1. Prerequisiti

Prima di iniziare, assicurati di avere installato sul tuo computer:

- **Python 3.9 o superiore** (verificabile con il comando `python --version` da terminale).
- Una connessione internet attiva (necessaria per scaricare il dataset da Tatoeba e le librerie Python).
- Circa **1 GB di spazio libero su disco** (il file di dati grezzi scaricato da Tatoeba è di alcune centinaia di MB).
- Facoltativo: **PyCharm** o un altro editor/IDE Python, se si vuole esplorare o modificare il codice.

2. Ottenere il progetto

Scarica o clona il progetto dalla repository GitHub in una cartella a tua scelta. Se hai Git installato, da terminale:

```
git clone <URL-della-repository>
cd language-detector
```

In alternativa, scarica lo ZIP del progetto da GitHub (pulsante "Code" → "Download ZIP") ed estrailo in una cartella.

3. Creare l'ambiente virtuale

Si consiglia di lavorare all'interno di un **ambiente virtuale Python** (virtual environment), per tenere le librerie del progetto isolate da quelle installate globalmente sul sistema.

Da terminale, nella cartella del progetto:

```
python -m venv .venv

# Attivazione su Windows:
.venv\Scripts\activate

# Attivazione su macOS/Linux:
source .venv/bin/activate
```

Se l'attivazione è andata a buon fine, il terminale mostrerà il prefisso (`.venv`) prima del percorso.

4. Installare le librerie necessarie

Tutte le librerie richieste sono elencate nel file `requirements.txt`. Installale tutte insieme con:

```
pip install -r requirements.txt
```

Le principali librerie installate saranno:

- **pandas** — gestione e pulizia dei dati
- **requests** — download dei dati da Tatoeba

- **scikit-learn** — feature extraction e modello di Machine Learning
- **joblib** — salvataggio/caricamento del modello allenato
- **flask** — server web e API

5. Costruire il dataset e allenare il modello

Questi script vanno eseguiti **una sola volta**, nell'ordine indicato, per generare il dataset e il modello allenato. Se il progetto scaricato include già i file nelle cartelle `data/` e `models/`, questo passaggio può essere saltato e si può procedere direttamente al punto 6.

5.1. Scaricare i dati grezzi da Tatoeba

```
python src/download_data.py
```

Scarica ed estrae il corpus di frasi multilingua. Può richiedere qualche minuto in base alla connessione internet, poiché il file è di alcune centinaia di MB.

5.2. (Facoltativo) Esplorare i dati grezzi

```
python src/explore_data.py
```

Mostra a schermo un riepilogo dei dati scaricati (numero di frasi totali e per ciascuna delle 5 lingue). Utile per verifica, non genera file.

5.3. Pulire e preparare il dataset finale

```
python src/clean_data.py
```

Filtra le 5 lingue, pulisce e bilancia i dati, salvando il risultato in `data/dataset_clean.csv` (15.000 frasi, 3.000 per lingua).

5.4. Allenare il modello

```
python src/train_model.py
```

Allena il modello di classificazione, ne stampa a schermo le prestazioni (accuracy e report per lingua), e lo salva nella cartella `models/` insieme al vectorizer. Il processo richiede generalmente pochi secondi/minuti.

Al termine di questo step, dovrebbero esistere due file: `models/language_model.joblib` e `models/vectorizer.joblib`.

6. Avviare l'applicazione web

Con il modello pronto (o già presente nel progetto scaricato), avvia il server Flask:

```
python app/app.py
```

Il terminale mostrerà un messaggio simile a `Running on http://127.0.0.1:5000`. Il server resta in esecuzione finché non viene fermato (Ctrl+C nel terminale).

Apri quindi un browser e visita l'indirizzo:

```
http://127.0.0.1:5000
```

Comparirà l'interfaccia dell'applicazione. Digita un testo nella casella: dopo una breve pausa nella scrittura, sotto la casella apparirà automaticamente la lingua rilevata con la relativa bandiera.

6.1 Interpretare i risultati

- Viene mostrato il **nome della lingua** rilevata, con bandiera corrispondente (IT, DE, EN, FR, ES).
- Se il testo inserito è molto breve (sotto i 10 caratteri), comparirà un avviso "**Testo breve: risultato meno affidabile**" — non è un errore, ma un'indicazione onesta sul livello di certezza atteso per input molto corti (vedi documentazione tecnica, sezione 6.2).

7. Arrestare l'applicazione

Per fermare il server, torna al terminale in cui è in esecuzione e premi `Ctr l+C`. Per uscire dall'ambiente virtuale attivato, digita `deactivate`.

8. Risoluzione dei problemi più comuni

Problema	Possibile causa e soluzione
"python non è riconosciuto" / "command not found"	Python non è installato o non è nel PATH di sistema. Reinstallare Python assicurandosi di averlo installato nel PATH di sistema.
Errore nel caricare i file .joblib	Il modello non è stato ancora allenato. Eseguire prima gli script della sezione 5 nell'ordine corretto.
La pagina web non si apre / "connessione rifiutata"	Il server Flask non è in esecuzione, oppure è stato chiuso. Verificare che il terminale mostrato nella sezione 6.1 sia aperto e che il server sia in esecuzione.
Il risultato non si aggiorna scrivendo	Verificare la connessione tra frontend e backend: controllare che il server sia attivo e che il frontend sia correttamente configurato.
Risultato sbagliato su parole molto corte	Comportamento noto e atteso su input di poche lettere: si veda la sezione 6.2 della documentazione.

Per approfondimenti su scelte tecniche e architettura, consultare il documento "Documentazione Tecnica" allegato al progetto.